

# 畳み込みニューラルネットワークを用いた 多数のパラメータによって特徴づけられる 波形の抽出とパラメータ推定

1 : 長岡技術科学大学

2 : 京都大学

○森雅也<sup>1</sup>, 中平勝子<sup>1</sup>, 田中貴浩<sup>2</sup>

# 背景: 既存の研究

- 波形解析
  - 離散化された信号の表現法・信号特性の抽出
    - 線形予測, 周波数解析, 時間-周波数解析, ...
  - 信号分離解析
    - ノイズ除去, 信号の基本成分/複数成分の分離, ... → 信号抽出
  - 抽出された信号の信号識別と特徴分析
    - クラスタ分析, NN, 多変量解析, ...
- 信号に対する特徴分析: 機械学習の応用
  - 時間整合アルゴリズムに基づくタイヤ振動解析法[1]
  - 大規模な自然電波のクラスタリング手法[2]
  - 重力波の直接検出とデータ解析[3]

[1]花塚泰史, “時間整合アルゴリズムに基づくタイヤ振動解析法-リアルタイム路面状態判別システムの開発-”, 2013.

[2]田中裕士, 後藤由貴, 笠原禎也, 南保英孝, “あけぼの衛星の大規模データセットを用いた自然波動の分類に関する研究”, 電子情報通信学会論文誌D, Vol.J101-D, No.1, pp.225-234, 2018.


[3]真貝寿明, “重力波の直接検出とデータ解析”, システム/制御/情報, Vol.62, No.9, pp.370-375, 2018.

# 背景：物理現象における観測波形

- 多くの物理量によって信号が表現される  
→パラメータ値推定によって物理現象を説明
  - 信号に対する分析：パラメータ推定には多くの方法がある
    - 例) Matched Filter: 予測波形と観測波形の相関解析から現象のパラメータ値を推定
    - パラメータが多数になると莫大な時間と計算コストが必要
- 例：重力波イベント『GW150914』の場合、  
1イベントに対して $\sim 2.5 \times 10^5$ パターンのパラメータ組み合わせ

	観測時間が短時間	観測波形が長時間
正確に波形予測可能	パラメータ推定：容易	パラメータ推定：困難
正確に波形予測不可能	パラメータ推定：MF使用不可	パラメータ推定：MF使用不可

- 雑音に対する分析：
  - 自然界における波形には大小さまざまなノイズが多数含まれている
  - ノイズの種類を特定できない
  - 物理情報を失う可能性



様々なノイズを含んだ波形から、効率よく多数のパラメータ値を推定する手法が必要

# 目的

## 最終目標

畳み込みニューラルネットワークを用いた波形のパラメータ値の推定



## 問題解決

波形データを画像データにすることで、  
正確な波形予測が困難な場合でも特徴を抽出できるのでは？  
畳み込みニューラルネットワークは画像分野において非常に優れている



## 本研究

畳み込みニューラルネットワークに適した波形データの前処理と

観測波形の特徴量抽出に適した

畳み込みニューラルネットワークの構成について検討

※本研究では具体的な対象として、重力波解析を念頭に置く

※ 重力波: 時空の曲率の時間変動が波動として光速で伝搬する現象

※ 本研究では波形があるパラメータ範囲に存在するか否かの2クラス分類を行う

# 実験手順: 全体の流れ

## STEP:1

### 教師データ (波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

正弦波に近い波形を想定した疑似データ

- 位相の時間発展を特徴付ける3つのパラメータを設定
- 雑音信号の混入: 信号/雑音比の組み合わせ

## STEP:2

### 波形データの 加工・処理

- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

2手法の入力

- スペクトログラム (位相情報なし)
- レインボーグラム (位相情報あり)

## STEP:3

### 畳み込みニューラル ネットワーク(CNN)の 構築

※出力は波形が、あるパラメータ範囲に存在するか否かの2クラス

検討すべき課題

- 層数の適切さ
- 学習回数
- 学習方法の検討 →  $\left\{ \begin{array}{l} \text{信号:雑音比 別々に学習} \\ \text{信号:雑音比 まとめて学習} \end{array} \right.$

# 実験手順(1): 教師データ生成

STEP:1

教師データ  
(波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

波形データの  
加工・処理


- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

畳み込みニューラル  
ネットワーク(CNN)の  
構築

※出力は波形が、あるパラメータ範囲に存在するか否かの2クラス

重力波観測波形を想定した疑似データの生成



緩やかに振動数が時間変化する波形

$$S(t) = \underbrace{A_{\text{signal}}}_{\text{振幅}} \times \cos(\phi(t))$$

$$\phi(t) = 2\pi \left\{ \underbrace{\alpha f_0 t}_{\text{基準周波数: 500[Hz]}} + \frac{1}{2} \underbrace{\beta (f_0 t)^2}_{\text{時間: 2[s]}} + \frac{1}{3} \underbrace{\gamma (f_0 t)^3}_{\text{時間: 2[s]}} \right\}$$

基準周波数: 500[Hz]      時間: 2[s]

周波数の時間変化

$$f(t) = f_0 \{ \underbrace{\alpha}_{\text{振幅}} + \underbrace{\beta (f_0 t)^2}_{\text{時間: 2[s]}} + \underbrace{\gamma (f_0 t)^3}_{\text{時間: 2[s]}} \}$$

位相の時間発展を決めるパラメータ

# 実験手順(1): 教師データ生成

STEP:1

## 教師データ (波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

## 波形データの 加工・処理

- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

## 畳み込みニューラル ネットワーク(CNN)の 構築

※出力は波形が、あるパラメータ範囲に存在するか否かの2クラス

## 重力波観測波形を想定した疑似データの生成

各パラメータ値

$$\alpha = \frac{p+q}{2}, \quad \beta = \frac{p-q}{1000}, \quad \gamma < 8.0 \times 10^{-8}$$

※  $0.1 < q < p < 1$  を満たす範囲



50[Hz]～500[Hz]間で緩やかに変化する波形

## ノイズの生成

$$n_i = A_{\text{noise}} \times X_i$$

$i$  : 時刻ラベル,  $X_i$  : 標準正規分布に従う独立な乱数,  $A_{\text{noise}}$  : ノイズの強度

信号/雑音比 (S : N)

$$\text{SNR} = \sqrt{\frac{8192}{2}} \left( \frac{A_{\text{signal}}}{A_{\text{noise}}} \right)^{\text{時系列データの長さ}}$$

S : Nが1 : 1の場合… SNR = 64

S : Nが1 : 2の場合… SNR = 32

S : Nが1 : 5の場合… SNR = 12.8

# 実験手順(1): 教師データ生成

STEP:1

教師データ  
(波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

波形データの  
加工・処理



- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

畳み込みニューラル  
ネットワーク(CNN)の  
構築

※出力は波形が、あるパラ  
メータ範囲に存在するか否  
かの2クラス

重力波観測波形を想定した疑似データの生成





# 実験手順(2): スペクトログラム生成

STEP:1

教師データ  
(波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

波形データの  
加工・処理



- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

畳み込みニューラル  
ネットワーク(CNN)の  
構築

※出力は波形が、あるパラメータ範囲に存在するか否かの2クラス

## 疑似データのスペクトログラムの生成



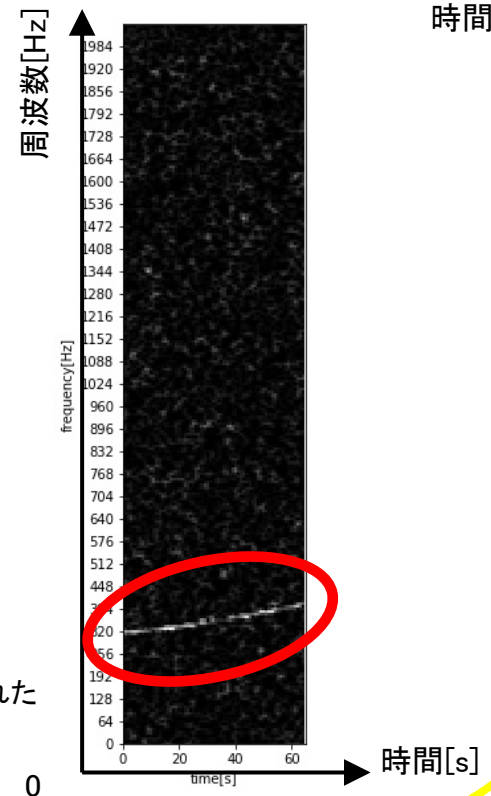
### 短時間フーリエ変換

- サンプル周波数 : 4096[Hz]
- 窓幅 : 512
- スライド幅 : 120
- 窓関数 : ハミング窓

### スペクトログラムの生成

$$S_{\text{power}}(\omega) = |F(\omega)|^2$$

フーリエ変換によって得られた  
周波数関数



# 実験手順(2): レインボーグラム生成

STEP:1

教師データ  
(波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

波形データの  
加工・処理


- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

畳み込みニューラル  
ネットワーク(CNN)の  
構築

※出力は波形が、あるパラメータ範囲に存在するか否かの2クラス

位相情報を考慮したスペクトログラムの生成



強度→明度  
位相情報→色相

位相情報の抽出

$$S_{\text{phase}}(\omega) = \arctan\left[\frac{\text{Im}F(\omega)}{\text{Re}F(\omega)}\right]$$


画像生成

$$R = 255 \times \text{Floor}\left[\left(1 - \frac{A}{A_{\max}}\right) \cos'(2\pi S_{\text{phase}}(\omega))\right]$$

$$G = 255 \times \text{Floor}\left[\left(1 - \frac{A}{A_{\max}}\right) \cos'\left(2\pi\left(S_{\text{phase}}(\omega) + \frac{1}{3}\right)\right)\right]$$

$$B = 255 \times \text{Floor}\left[\left(1 - \frac{A}{A_{\max}}\right) \cos'\left(2\pi\left(S_{\text{phase}}(\omega) + \frac{2}{3}\right)\right)\right]$$

$$\cos'(a) = \frac{\cos_{\text{org}}(a) - \cos_{\min}}{\cos_{\max} - \cos_{\min}}$$



# 実験手順(3): CNNの構築

STEP:1

教師データ  
(波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

波形データの  
加工・処理

- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

畳み込みニューラル  
ネットワーク(CNN)の  
構築

※出力は波形が、あるパラメータ範囲に存在するか否かの2クラス

CNNの学習の流れ

入力データ(256,65,3)



畳み込み層(25,10,3,16)



プーリング層(4,5)



ReLU関数

畳み込み層(10,4,32)



プーリング層(4,1)




ReLU関数



1層



3層



5層

# 実験手順(3): CNNの構築

STEP:1

教師データ  
(波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

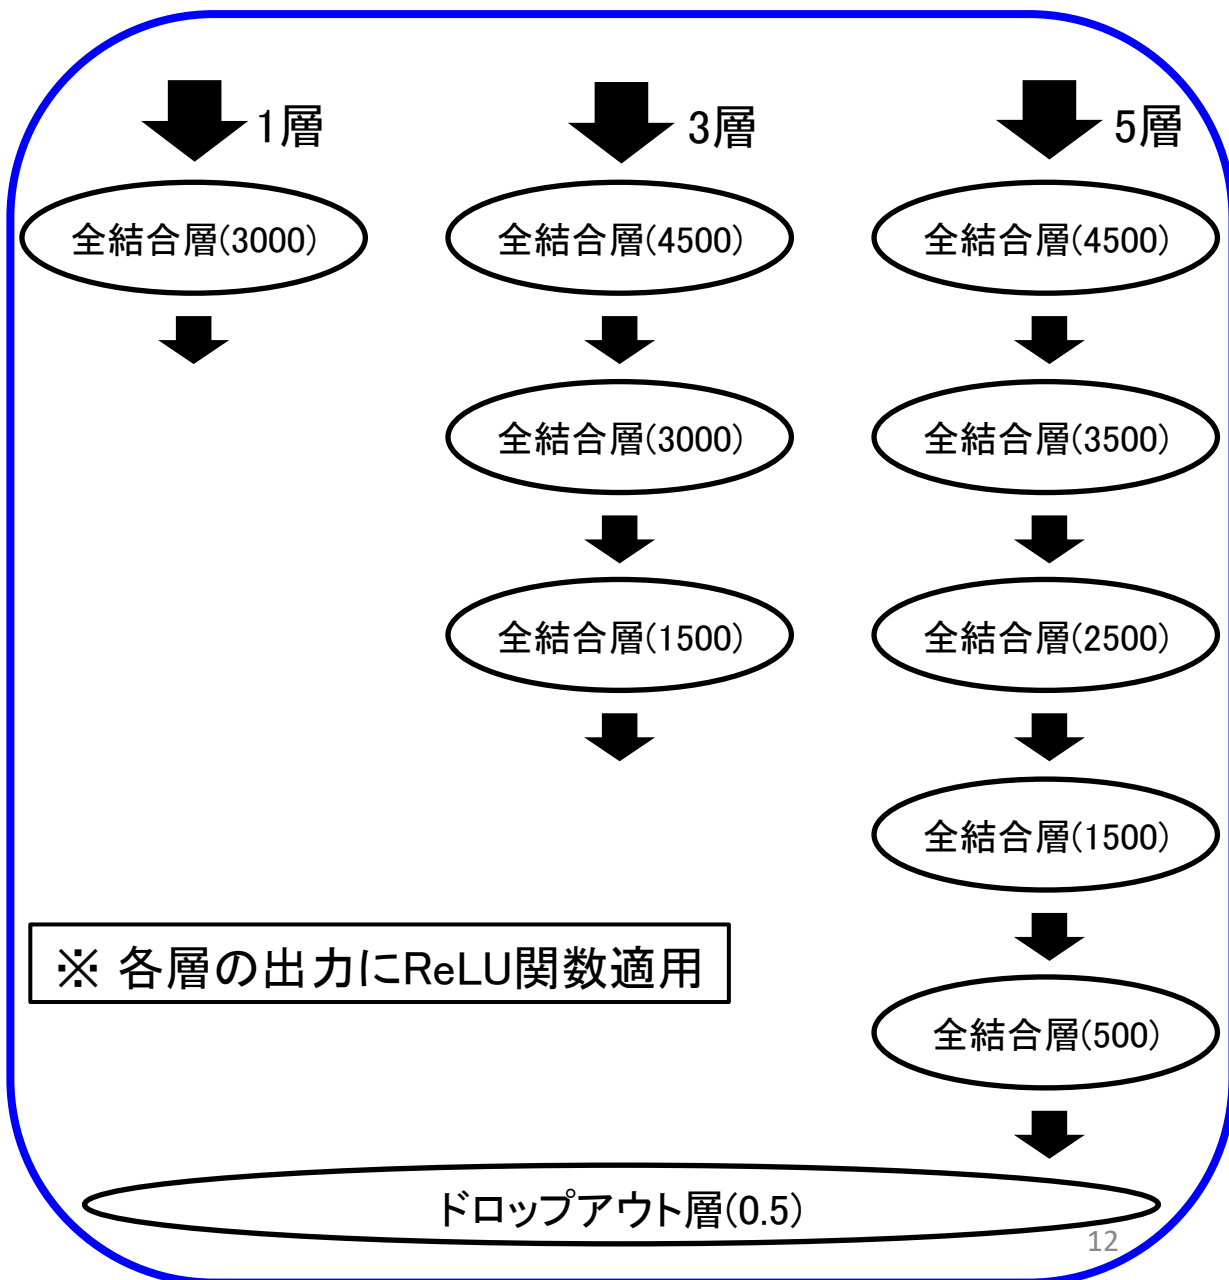
波形データの  
加工・処理

- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

畳み込みニューラル  
ネットワーク(CNN)の  
構築

※出力は波形が、あるパラ  
メータ範囲に存在するか否  
かの2クラス



# 実験手順(3): CNNの構築

STEP:1

教師データ  
(波形データ)の生成

※本研究では重力波に見立てた疑似データを使用する

STEP:2

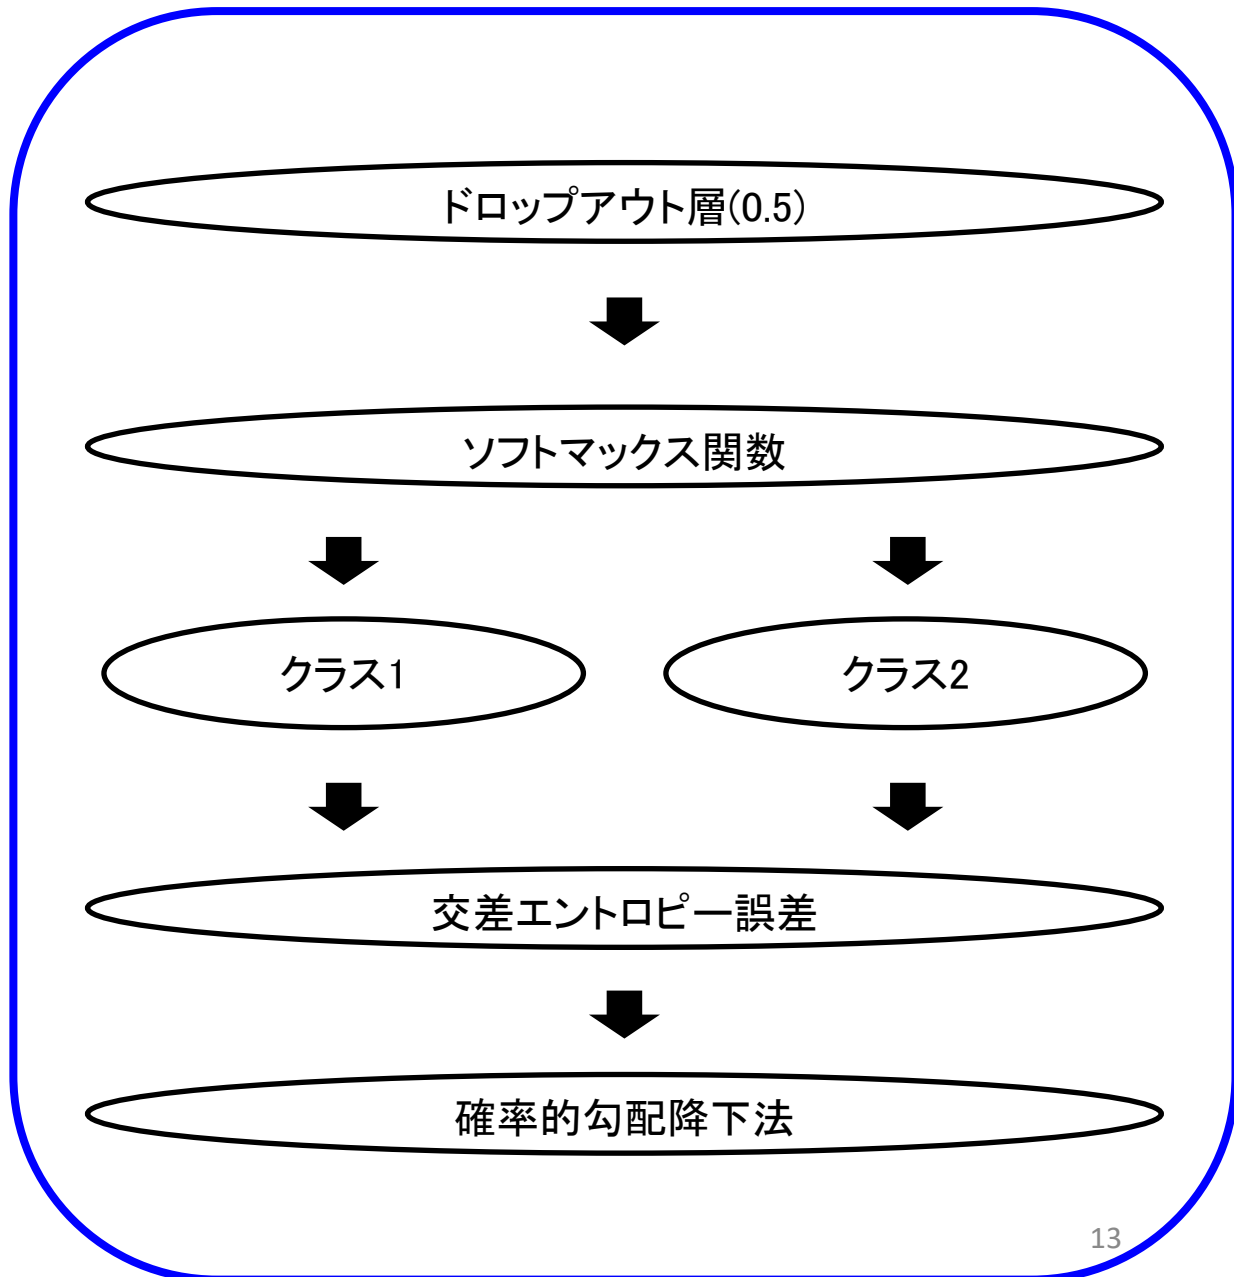
波形データの  
加工・処理

- ✓ 短時間フーリエ変換
- ✓ スペクトログラムの生成

STEP:3

畳み込みニューラル  
ネットワーク(CNN)の  
構築

※出力は波形が、あるパラ  
メータ範囲に存在するか否  
かの2クラス



# 結果 : SNRごとに学習させた場合の判定率

クラス1 : 50~500[Hz]間で緩やかに変化する波形  
クラス2 : 10~50[Hz], 500~1000[Hz], 1000~2048[Hz]間で緩やかに変化する波形

教師データ:テストデータ  
7000:2000

表1 : 学習回数2,000回時におけるパワースペクトルでの結果

$A_{\text{signal}} : A_{\text{noise}}$	1 : 0	1 : 1	1 : 2	1 : 3	1 : 5
1層	.999	.997	.997	.505	.499
3層	.998	.998	.998	.500	.503
5層	.998	.998	.998	.506	.509

表2 : 学習回数100,000回時におけるレインボースペクトログラムでの結果

$A_{\text{signal}} : A_{\text{noise}}$	1 : 0	1 : 1	1 : 2	1 : 3	1 : 5
1層	.999	.998	.998	.487	.491
3層	.999	.999	.998	.510	.517
5層	.999	.998	.998	.498	.506

## 考察

- SNRが“1 : 0”, “1 : 1”, “1 : 2”の場合は約99%の正答率
- 層数が少ない場合でも分類可能
- SNRが“1 : 3”, “1 : 5”の場合は正答率が約50%
  - パワースペクトル・位相情報だけでは情報不足
  - 学習方法が不適切

# 結果：SNRを同割合で学習させた場合の判定率

クラス1：50～500[Hz]間で緩やかに変化する波形

クラス2：10～50[Hz], 500～1000[Hz], 1000～2048[Hz]間で緩やかに変化する波形

- SNRごとに分けていたデータをまとめて教師データに  
→ 入力は 信号/雑音比 1 : 0 から 1 : 5 までのレインボースペクトログラム
- 3層の場合のみで検証

教師データ:テストデータ  
15000:3000

表3：学習回数10,000回時におけるレインボースペクトログラムでの結果

$A_{\text{signal}} : A_{\text{noise}}$	混合	1 : 3	1 : 5
3層	.826	.775	.767

## 考察

- 信号/雑音比が 1 : 3 の場合: 51.0% → 77.5%
- 信号/雑音比が 1 : 5 の場合: 51.7% → 76.7%  
→ 判別率が 25% 向上



SNRごとに学習させるよりも  
各SNRを同割合で学習させた方がよい

## 畳み込みニューラルネットワークに適した波形データの前処理と 観測波形の特徴量抽出に適した 畳み込みニューラルネットワークの構成について検討

### 検討の手順

1. 重力波信号を単純化した疑似波形の生成
2. ノイズを付加
3. 短時間フーリエ変換
4. スペクトログラムの導出
5. スペクトログラムを入力とするCNNの構成

### 結果

- 信号/雑音比が 1 : 2 までなら正確に特徴を捉えることが可能
- CNNの層数が少なくても識別可能
- 教師データのSNRを同割合で学習させる  
→ 判別精度向上
- 信号/雑音比が1 : 5 の場合でも**判別率77.5%**

### 今後の展望

- 信号/雑音比が1 : 5 の場合でも**判別率77.5%**  
→ より大きい雑音の場合でも検証  
→ より高い判別率の追求
- 雑音を正常、信号を異常とした**異常値検知問題**の実装  
→ 本来、**信号がある方が稀**  
→ 雑音に対して信号が小さいため、**信号がある状態を異常として検出**

	短時間	長時間
波形予測可能	容易	困難
波形予測不可能	MF使用不可	MF使用不可



# 観測対象と解析方法

	短時間 (重力波イベント)	長時間 (定常重力波)
波形 予測可能	 <p>連星の合体 → チャープ波</p> <p>ガンマ線 バースト</p>	 <p>パルサー, LMXB → 連続波</p>
波形が 予測できない	 <p>超新星爆発 → バースト波</p>  <p>ソフトガンマ線 リピータ</p>	 <p>背景重力波 → 定常ランダム波</p>